合肥工業大學

计算机与信息学院

智能应用系统设计报告

基于机器学习的智能投资顾问系统

专　业　班　级 _____

姓　名　及　学　号 _____

课 程 教 学 班 号 _____

任　课　教　师 _____

2026~2027 学年第 一 学期

说　明

课程设计报告是关于实践教学内容、过程及效果的记录和总结，因此，应注意以下事项和要求：

1．课程设计报告要求：**格式规范、语言表达清楚、数据和代码真实。并能够理论联系实际，认真分析实践中出现的问题与现象，总结经验。**

2．每位同学应独立完成实践报告的撰写，严禁抄袭或拷贝，否则，一经查实，按作弊论处。

3. 可根据实际需要调整每个单元格的篇幅。

4. 请按照要求填写课程设计报告。部分核心代码可放置在附录中。

5. 格式应美观并保持统一，中文采用宋体、英文采用 Times New Roman 字体。

任务名称 基于机器学习的智能投资顾问系统

实践开展时间： ____年__月__日

课程设计内容

一 题目内容和要求

1.1 选题及完成情况

本项目选择第 27 题基于机器学习的智能投资顾问系统，实现知衡 InvestLab 本地软件，包含股票咨询、买卖账本、风险预警、资产配置、模型实验室、用户画像、市场行业、组合风险、回测验证和投资学堂。系统已完成本地模型训练、公开数据读取和交互界面，可持续更新数据和生成候选模型。本文记录实际实现及 2026 年 10 月 29 日的实验结果，不把功能实现等同于投资有效性。

1.2 需求边界

判断模型分析历史量价特征，语言模型解释检索证据，确定性程序计算盈亏和资金约束。软件不连接券商交易接口。新闻监测采用无需账号的公开财经来源，已替代微博。NPU 尚未部署，训练及推理使用 CPU。

二 问题背景和相关工作介绍

2.1 研究背景

股票研究需要结合价格变化、经营披露和舆情。历史价格低位不等于估值便宜，负面关键词不等于事件属实。本项目将数值信号、公告原文和新闻线索分别展示，并保留来源和时间，避免把传闻直接转化为卖出指令。

2.2 模型选择

判断模型采用 LightGBM 方向分类器与下探事件分类器。语言模型为 Qwen3 4B Instruct 2507 的 Q4_K_M 量化版本，权重约 2.4GB，通过 llama.cpp 在 CPU 运行，适配 32GB 内存和无独立显卡环境。该选择为工程折中，没有通过多模型基准证明绝对性价比最优。组合使用 LedoitWolf 收缩协方差和 SLSQP 约束优化。

三 解题思路

3.1 架构与模块

本机 HTTP 服务连接浏览器和 Python 模块，SQLite 保存交易、设置与事件，JSON 保存缓存和版本清单。market 负责来源适配，universe 负责行业目录，models 负责训练，llm 负责语言解释，store 负责账本，alerts 负责巡检，updates 负责独立更新，public_news 负责公开快讯读取及股票匹配。所有业务可脱离对话助手在本机运行。

前端为本地 HTML、CSS 和 JavaScript，采用柔和玫红主题，正收益红色、负收益绿色。服务只监听 127.0.0.1，校验请求来源；成本、数量和资产预算不会发送给云端语言模型。

3.2 行情与及时性

最新报价来自腾讯证券公开接口，带来源时间；页面每 30 秒刷新，本地缓存 20 秒。工作日交易时段报价超过 5 分钟标为过期，公开来源没有延迟服务保证，尚未接入完整交易所日历。休市显示最近报价，不能冒充即时成交价。

历史日线优先使用新浪日线和官方前复权因子，备用东方财富及腾讯接口。训练数据须为前复权且至少 300 条有效日线。程序检查日期去重、正价格、最高最低价关系和成交量；15 时 15 分前排除未完成当日日线。实际采集遇到备用接口连接关闭和 501 错误，增加新浪来源后完成扩大训练。

公司公告索引、公告正文和新闻来自东方财富。财报通过上市公司公告读取，并非已实现通用公司官网爬虫。每次查询保留来源、日期、链接和错误，读取失败不等于没有风险。

3.3 股票池与未见股票

股票池按新浪公开行业目录更新，排除非行业的次新股分类，共 48 个来源分类、374 只候选。这一分类不是申万 2021，包含综合等历史类别。每行业选最多 5 只有效公司，通常 4 只训练、1 只留出，保证实际训练不少于 3 只；不足时整轮失败并保留原模型。最终 191 只训练、48 只留出。

输入未见股票时，程序仍可以获取其日线和资料，应用共享量价模型；界面显示训练成员状态及超出训练特征 1%至 99%范围的数量。检索获得新事实与模型权重学习是两个过程，任何一个都不能保证预测正确。

3.4 特征 标签和时间隔离

14 项特征包括 1、5、20、60 日收益，5、20、60 日波动，5、20、60 日均线偏离、振幅、20 日相对成交量、60 日回撤和 120 日位置。特征只读取当日及以前数据；预热 120 日。

方向标签以次日开盘至第五个后续交易日收盘收益扣除 0.2%费用计算，大于 1%为上涨，小于负 1%为下跌，其余震荡。下探事件为未来五个交易日最低价低于当日收盘的 97%。未来窗口不完整不产生标签。

按共同日期约 60%、15%、10%、15%划分训练、验证、校准和测试，剔除跨边界标签。LightGBM 最多 350 轮、15 叶、学习率 0.04、最小叶样本 70，随机种子 27，8 线程。下探概率经独立区间逻辑回归校准，方向分数未校准。

3.5 语言解释及外部证据

语言模型读取量化结果、公告、新闻和财报局部摘录，输出定性解释。联调发现小模型可能误读数值，因此页面直接展示程序算出的概率，生成端限制数值复述，过滤明显数字句和无效引用。格式过滤不代表语义完全可靠，用户仍需核对原文。

公开新闻由东方财富公司新闻检索与新浪财经 7×24 快讯共同提供，无需账号或密钥。新浪每次读取最近 100 条，优先按股票标签匹配；缺少标签时才按代码或完整简称匹配，减少关联公司误匹配。记录发布时间、抓取时间和来源，接口失败明确显示。实测新浪取得 100 条快讯，东方财富取得 15 条公司新闻，并验证股票 603002 匹配一条新浪快讯，完整调用未报错。微博已从运行链路和界面移除，公开快讯不等于社交平台全量舆情。

3.6 买卖账本与盈亏

用户输入代码、时间和数量，系统自动预填当日未复权收盘价，当天盘中使用最近报价。日线不能恢复用户实际成交价，预填必须允许修改。价格或费用未经核对时标为估算，不能称作券商确认收益。

买入增加股数和含费成本；卖出按移动加权成本释放成本，已实现盈亏等于卖出净收入减释放成本。浮动盈亏等于最新市值减剩余成本，累计盈亏为两者之和。支持部分卖出、全平仓和撤销误录，回放完整历史以阻止超卖、倒序录入造成负持仓和当天买入当天卖出。不包含分红、送转及利息。

3.7 巡检 配置和自动更新

持仓巡检每次完成后 120 秒再运行，筛查最近 72 小时公告、公司新闻和公开财经快讯；新闻及公告索引缓存 60 秒。关键词命中、辟谣降级、重复去重及错误记录落库；通知需要页面打开，浏览器通知还需用户授权。采集、训练与预警分别调度。

配置从每个训练行业选择一只普通板块代表股，按历史协方差和模型信号优化。稳健默认投入 65%、进取 85%，用户可自行指定投入金额。总资金大于 500 元即可计算，不再强制至少四只股票。个股 25%、行业 30%或 40%作为分散软目标；先求连续权重，再按 100 股取整并补配余款，尽量接近目标投入。每只股票一手仍买不起时如实保留现金。支持手动改股数和预算检查，不改变实际账本。点击推荐股票弹出 20、60、120 或 250 交易日蜡烛图与成交量。

后台默认每 15 分钟更新关注公司资料，每周刷新行业目录，工作日 16 时 15 分后每天最多训练一次。候选需满足覆盖、未见股票基线、当前版本比较以及新增 20 个成熟测试交易日要求；亏损且落后等权基准时禁止自动替换。旧版保留可回退，失败写入日志。更新脚本也可单独运行，跨进程锁防止并发训练。语言模型仅检索更新知识，不自动微调权重。关机、休眠和退出程序会停止任务，未设置 Windows 开机启动。

3.8 课程要求补全与用户画像

题目 27 的八项要求对应用户画像、资产配置、市场行业、组合风险、回测验证、个性化策略、投资学堂及投资者保护。十题问卷参考公开银行测评维度，由本项目自行设计 0 至 30 分规则，覆盖经验、知识、收入、债务、备用金、投资占比、期限和损失承受能力。形成五级画像及五维图，保留最近 50 次记录；365 天后提醒重评。画像影响风险优化与适配提示，用户自定配置金额不再被静默压低。产品类别与策略说明按画像区分，不冒充正式银行测评或认证。

行业模块比较 48 个来源行业各三只代表股的 20 日、60 日收益和相对加速度；宏观优先读取国家统计局，实测本机官方站点连接失败，备用读取财经新闻并标记需核查。宏观解读为条件提示，未建立因果预测模型。组合风险按当前股票权重回放历史，展示集中度、年化波动、历史 VaR 与回撤，每分钟在页面刷新；配置显示当前持仓与目标差额，不执行交易。投资学堂提供五项知识及理解测试。来源披露、风险揭示、画像留档和本机访问限制构成课程投资者保护措施，不能据此声称商业投顾合规认证。

3.9 独立的短期与长期研究

咨询和配置均可选 5 交易日短线或 60 交易日季度长线。长线采用独立 LightGBM 收益回归器，使用同一 14 项历史特征，标签为次日开盘至第 60 日收盘扣 0.2%费用收益，训练、验证、测试按时间隔离并剔除跨界标签。60 日不是多年投资预测，财务因子模型尚未实现。

长周期训练 81469 条、验证 22459 条、测试 34165 条，测试日期 2025 年 11 月 3 日至 2026 年 7 月 28 日。已见股票 MAE 为 0.162259，常数基线 0.162219；未见股票 8582 条，MAE 为 0.148478，基线 0.148376。两者均未优于常数，因此界面提示弱有效性，长期配置关闭收益择股分数，只使用风险优化。自动晋升新增长期基线检查。长期模块报告预测误差，没有伪造长期策略回测。

四 算法伪代码

4.1 数据到候选模型

```
刷新行业目录并获取各行业候选日线
检查复权 数据质量 和每行业至少三只训练公司
分别保留训练公司与未见测试公司
构建仅依赖过去的特征与成熟未来标签
按时间划分训练 验证 校准 测试并清除边界重叠
训练方向和下探分类器 校准下探概率
```

评估已见和未见股票 保存指标 数据哈希和版本
通过全部晋升门槛时启用 否则保留当前版本

4.2 买卖账本

按成交时间排序所有有效记录
买入时增加股数 成本加上成交金额和费用
卖出时验证可卖数量并按比例释放加权成本
卖出净收入减释放成本得到本笔已实现盈亏
当前市值减剩余成本得到浮动盈亏
撤销误录前重放剩余账本 确保后续卖出仍有效

五 课程设计环境与实验设置

5.1 运行环境

Windows 本地环境、32GB 内存、无独立显卡。Python 本地服务与 LightGBM 在 CPU 运行，Qwen 量化模型通过 llama.cpp CPU 服务运行。NPU 没有进行兼容性或加速测试。依赖和模型来源清单随源码保存。

5.2 实际数据划分

扩大版本为 20261029-073725，191 只训练股票共 171518 个有标签样本。48 只未见股票另有 6854 个测试样本；训练清除边界重叠后保留以下区间。

区间	开始	结束	样本数
训练	2022-11-22	2025-03-20	98271
验证	2025-03-28	2025-10-21	26094
校准	2025-10-29	2026-03-12	16984
测试	2026-03-20	2026-10-21	27304

5.3 验证口径

模块测试使用隔离数据库；实际接口验证咨询、组合、本地推理和更新任务。虚构交易仅用于验收，之后撤销。研究回放每五个测试交易日选择上涨分数大于 0.45、下探概率小于 0.4 的公司，采用标签中的收益与费用，未模拟涨跌停、退市、停牌和实际成交冲击。

六 课程设计结果

6.1 扩大模型的结果

指标	实测值
训练公司与留出公司	191 只与 48 只
行业覆盖	48 类 每类至少 3 只训练公司

采集加训练耗时	248.41 秒
已见股票方向 Macro F1	0.3010 多数类基线 0.2075
已见股票下探 Brier	0.2296 常数基线 0.2587
未见股票方向 Macro F1	0.3160 多数类基线 0.2149
未见股票下探 Brier	0.2325 常数基线 0.2594
预设策略研究回放收益	约负 29.07%
同期等权基准收益	约负 7.62%

较旧版在同一未见样本上的 Brier 由 0.2367 改善为 0.2325，但策略回放显著亏损。扩大版作为课程研究版本启用，不能作为有效买卖策略。自动晋升增加回放劣于基准拦截，后续不得仅凭分类指标改善替换。

6.2 账本与交互

参考价查询实测 600900 在 2025 年 1 月 2 日未复权收盘为 29.20 元。虚构买入 200 股、单价 28 元、费用 5 元，成本 5605 元；次日以 29 元卖出 100 股、费用 5 元，释放成本 2802.50 元，已实现 92.50 元。核对价格前界面标为估算。

界面包含参考价预填、可编辑价格、卖出记录、已实现与浮动盈亏、来源时间、未见股票说明、行业覆盖和更新日志。颜色采用红涨绿跌规则。完整真实调用证据保存在 output 目录。

6.3 尚未完成的验证

公开新闻的连续运行到达率尚待长期测量；长期多日通知到达率、完整交易日历、公司行为账本、历史退市成员、公司官网通用爬取、滚动前向评估和 NPU 部署尚未完成。更新能力不表示能自动修复任何第三方接口变动。

6.4 一致性修复与桌面交付

组合与咨询共用判断、公告和新闻流程；自动备选要求上涨估计严格高于下跌，并排除高下探风险和近期公告风险关键词。提供多种组合与单股备选，刷新时轮换候选。风险画像自动设置风格与投入，但允许手动覆盖。成交录入同时显示股数乘参考价及加减费用后的净收支。开屏展示风险声明，程序不执行交易。方向概率仍未校准，已有回测不代表新版组合规则的业绩。旧测试数据库隔离缺陷已修复，增加临时目录强制检查和启动账本快照。

七 结果分析

7.1 工程功能和预测有效性

本地软件能够独立查询、训练、记录交易和运行更新任务；但方向分辨能力较弱，预设规则回放明显落后基准。下探 Brier 优于常数只说明本区间概率误差较低，不能推导到收益。当前行业成员存在幸存者偏差，复权历史为当前快照，测试区间亦非长期前向运行。

7.2 改进方向

应积累新的成熟数据开展滚动前向验证，比较简单策略及市场基线，并引入财务、行业相对特征。舆情需要人工标注测量误报和漏报。账户应补充分红送转与券商对账，风险问卷及期限已接入，但评分尚需专业校准，长期预测仍需验证。不能反复调整阈值以迎合已经查看的测试收益。

八 总结

本项目完成可运行的本地双模型研究软件，并将一次性训练扩展为资料获取、候选训练、评估、版本保留和有条件晋升的持续流程。软件能够获取陌生股票资料，但不能保证分析正确。报告保留失败接口和亏损回放，明确来源连续可用性、长期验证与硬件部署等尚未完成边界。

九 附录 算法源代码与参考资料

9.1 源码和复现

app.py 为入口，investlab 包含业务模块，web 包含界面，tests 包含检查，scripts 包含模型安装和更新脚本。data/models 保存模型和清单，data/runs 保存训练快照，data/knowledge 保存证据，data/app.db 保存交易。源码包不包含个人数据库。另提供 Windows 便携程序，包含判断权重、Qwen 量化模型与训练推理运行库，解压后双击启动；个人数据保存到独立 user-data 目录。

9.2 参考资料

[1] 智能应用系统课程设计 2026 发布文件 投资顾问题目 第 23 页。

[2] 智能应用系统课程设计报告 2025 模板。

[3] LightGBM 官方项目 https://github.com/microsoft/LightGBM

[4] Qwen 官方模型 https://huggingface.co/Qwen/Qwen3-4B-Instruct-2507

[5] llama.cpp 官方项目 https://github.com/ggml-org/llama.cpp

[6] 新浪财经 7×24 公开新闻页面 https://finance.sina.com.cn/7x24/

[7] 新浪行业目录 https://vip.stock.finance.sina.com.cn/q/view/newSinaHy.php

[9] 中国银行个人客户风险测评说明，2026 年 3 月。

https://pic.bankofchina.com/bocappd/wealth/cs82/202603/P020260327646673351867.pdf

[10] 国家统计局数据发布。

https://www.stats.gov.cn/sj/zxfb/

[8] scikit learn LedoitWolf 官方文档。

https://scikit-learn.org/stable/modules/generated/sklearn.covariance.LedoitWolf.html

模型下载版本与哈希保存在 models/download_manifest.json，公开资料核验与本次扩大实验日期为 2026 年 10 月 29 日。封面个人信息仍需填写，PPT 暂未制作。

● 感想 体会 建议

实践表明，自动化需要明确失败条件、数据时间和可复现记录。扩大样本并没有自动解决盈利问题，真实亏损回放更能说明模型需要改进。把账本计算交给确定性程序，把资料归纳交给语言模型，再为更新设置检验门槛，有助于分别检查各环节，而不是依赖一段看似肯定的自然语言结论。